

Documento di Prova per Pipeline RAG

1. Cos'e' un sistema RAG

Retrieval-Augmented Generation (RAG) e' un'architettura che combina un modello linguistico con una base documentale esterna. Invece di affidarsi solo alla conoscenza appresa in fase di addestramento, il modello recupera frammenti di testo rilevanti da un indice e li usa come contesto per generare la risposta. Questo permette di rispondere su documenti che il modello non ha mai visto, senza riaddestrarlo.

Il flusso si divide in due fasi. La fase offline indicizza i documenti: caricamento, suddivisione in chunk, calcolo degli embedding e archiviazione in un vector store come FAISS. La fase a runtime, eseguita a ogni domanda, trasforma la query in un vettore, recupera i chunk piu' vicini e li passa al modello come contesto.

2. Embedding e Vector Store

Un embedding e' una rappresentazione numerica densa di un testo, costruita in modo che testi semanticamente simili abbiano vettori vicini nello spazio. Il vector store conserva questi vettori e fornisce una ricerca per similarita': data una query, restituisce i documenti il cui embedding e' piu' vicino secondo una metrica come la distanza euclidea o il coseno.

FAISS, sviluppato da Facebook AI, e' una libreria efficiente per la ricerca di similarita' su grandi insiemi di vettori. In LangChain viene avvolto da una classe che lo rende compatibile con l'interfaccia Runnable, cosi' da poterlo comporre nelle catene LCEL come un qualsiasi altro componente.

3. Chunking e Valutazione

La suddivisione in chunk e' critica: chunk troppo grandi diluiscono il segnale e saturano il contesto, chunk troppo piccoli perdono coerenza. Una strategia comune usa una dimensione di circa mille caratteri con una sovrapposizione di duecento, per non spezzare le frasi a meta'.

La valutazione di un sistema RAG puo' avvenire con l'approccio LLM-as-a-Judge: un modello giudice confronta la risposta della pipeline con una risposta di riferimento e assegna un punteggio. Aggregando molti giudizi si ottiene una metrica che approssima la qualita' complessiva del sistema.